Struktura przestrzeni MNIST w reprezentacji PCA+QDA

Jakub Furmanek

Cel. Sprawdzamy wpływ PCA (wymiar k) na QDA oraz czy odległość Bhattacharyya przewiduje pomyłki klasyfikatora.

1 1. Przygotowanie danych i modelu

- MNIST: 70000 obrazów, wektor cech 784 (28×28 spłaszczone); normalizacja $X \leftarrow X/255$.
- Podział: trening/test = 70/30 (stratyfikacja).
- Dla ustalonego k: dopasowanie PCA na treningu, transformacja trening/test, a następnie QDA w przestrzeni PCA.
- Z QDA ekstrahujemy parametry klas: średnie μ_c i kowariancje Σ_c dla cyfr $c = 0, \ldots, 9$.

2 2. PCA i QDA

QDA

Zakładamy model gaussowski w przestrzeni PCA:

$$X \mid c \sim \mathcal{N}(\mu_c, \Sigma_c), \qquad \Sigma_c \leftarrow \Sigma_c + \lambda I,\ \lambda = 10^{-6}.$$

3 3. Macierz odległości Bhattacharyya

Dla $\mathcal{N}(\mu_1, \Sigma_1)$ oraz $\mathcal{N}(\mu_2, \Sigma_2)$:

$$D_B = \frac{1}{8}(\mu_1 - \mu_2)^\top \Sigma^{-1}(\mu_1 - \mu_2) + \frac{1}{2}\ln\left(\frac{\det \Sigma}{\sqrt{\det \Sigma_1 \det \Sigma_2}}\right), \qquad \Sigma = \frac{\Sigma_1 + \Sigma_2}{2}.$$

Dla ustalonego k liczymy macierz 10×10 dla wszystkich par cyfr i wizualizujemy ją jako heatmapę.

Uwaga numeryczna. Teoretycznie $D_B \geq 0$ (dla dodatnio określonych kowariancji), jednak przy estymacji Σ_c w wyższych wymiarach oraz obliczeniach wyznaczników/logarytmów mogą pojawić się wartości ujemne jako artefakt numeryczny. W takich przypadkach D_B traktujemy przede wszystkim porządkowo (ranking par klas), a wnioski konfrontujemy z macierzą pomyłek.

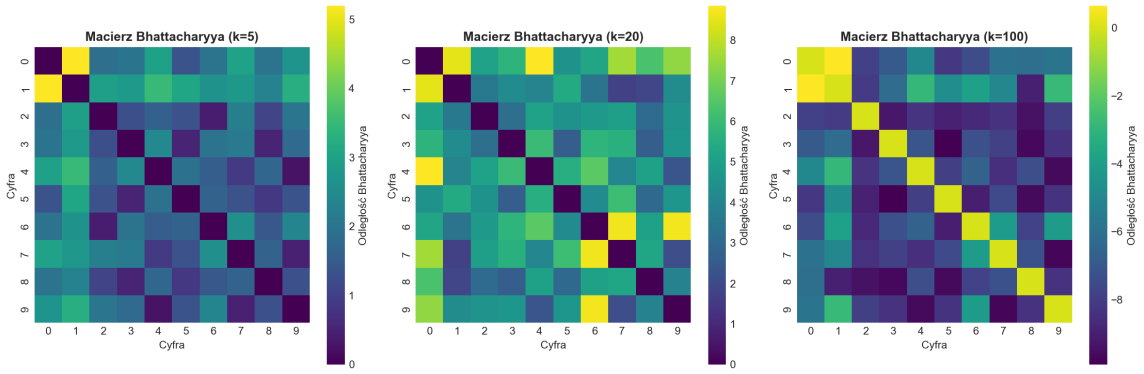

Rysunek 1: Heatmapy macierzy Bhattacharyya dla przykładowych wartości k.

Najmniejsze odległości (przykład). Dla $k = 50$ najmniejsze (najbardziej "nakładające się") pary to: 3–5 ($D_B = -10.08$), 7–9 ($D_B = -9.92$), 3–8 ($D_B = -9.83$).

4 4. Wpływ liczby składowych k

Badamy $k \in \{5, 10, 20, 30, 50, 70, 100\}$: PCA $\rightarrow$ QDA $\rightarrow$ accuracy, macierze pomyłek i macierze D_B.

Tabela 1: Accuracy QDA oraz statystyki D_B (średnia/min/max po parach klas, górny trójkąt bez przekątnej).

k	Accuracy	$\overline{D_B}$	$\min D_B$	$\max D_B$
5	0.7195	1.9300	0.2600	5.2000
10	0.8846	3.3700	0.7700	8.7200
20	0.9436	4.8900	1.7000	8.8500
30	0.9452	0.5300	−6.8000	5.3300
50	0.9359	−7.6600	−10.0800	−1.0900
70	0.9295	−7.4100	−9.9800	−0.5000
100	0.9203	−7.1900	−9.9200	0.6500

Obserwacja. Dokładność QDA rośnie od małych wymiarów do okolic $k \approx 30$, a następnie spada dla większych k (Tab. 1). Jest to spójne z tym, że QDA wymaga estymacji pełnych macierzy kowariancji, co w wyższych wymiarach może prowadzić do problemów numerycznych i pogorszenia uogólniania mimo małej regularyzacji λ.

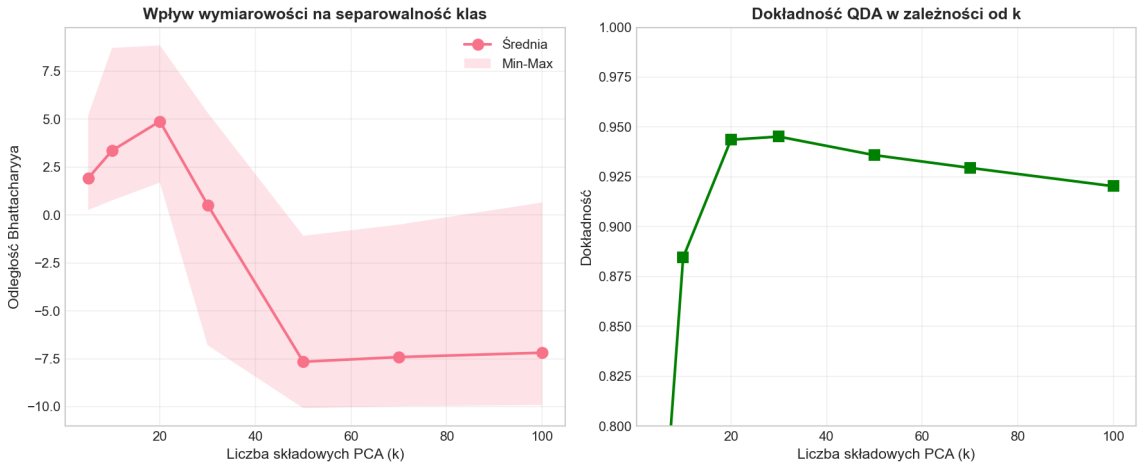

Rysunek 2: Wpływ k na separowalność (statystyki D_B) i dokładność QDA.

Stabilność "trudnych" par cyfr

Dla każdego k można analizować, czy pary o najmniejszym D_B (np. top-3) powtarzają się (stabilność rankingów) czy zmieniają się wraz z k. W praktyce raportujemy (i) statystyki $\min/\overline{D_B}$ jako funkcję k oraz (ii) listy top-par dla wybranych k, aby sprawdzić, czy te same cyfry konsekwentnie są najbliżej w sensie D_B. Jeżeli dla większych k pojawiają się wartości ujemne (Tab. 1), traktujemy to jako sygnał możliwych problemów numerycznych i interpretujemy wyniki głównie porządkowo (ranking), dodatkowo odnosząc je do macierzy pomyłek.

5 5. Związek z błędami klasyfikacji

Dla wybranego k (tu: $k = 50$) liczymy macierz pomyłek oraz korelację Pearsona między D_B (pary klas, bez przekątnej) a częstością mylenia pary.

Definicja częstości pomyłki pary. Z macierzy pomyłek CM definiujemy błąd warunkowy "$i \to j$" jako

$$e_{i\to j} = \frac{CM_{i,j}}{\sum_t CM_{i,t}}, \quad i \neq j,$$

a dla pary $\{i, j\}$ bierzemy średnią z obu kierunków:

$$\bar{e}_{i,j} = \frac{e_{i\to j} + e_{j\to i}}{2}.$$

Korelację liczymy dla wszystkich par $i < j$ (bez przekątnej).

- Dla $k = 50$: $r = -0.427$ (istotność można uzupełnić przez obliczenie p-value testem Pearsona).
- Najmniejsze D_B (największe nakładanie) dla $k = 50$: 3–5 ($D_B = -10.08$), 7–9 ($D_B = -9.92$), 3–8 ($D_B = -9.83$).

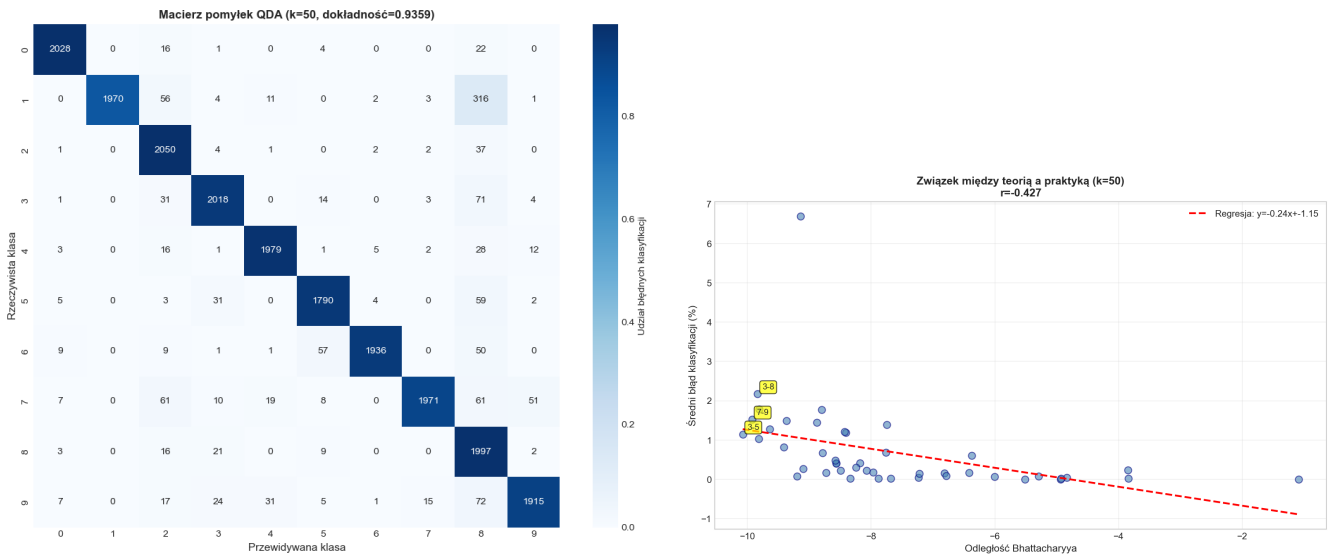

(a) Macierz pomyłek QDA ($k = 50$).

(b) D_B vs średni błąd pary klas, regresja.

Rysunek 3: Teoria vs praktyka: separowalność (D_B) a pomyłki QDA.

6 6. Wizualizacja przestrzeni PCA i dyskusja

Dla małego k (np. $k = 2$) wizualizujemy próbki w PCA oraz (dla QDA) elipsy kowariancji klas.

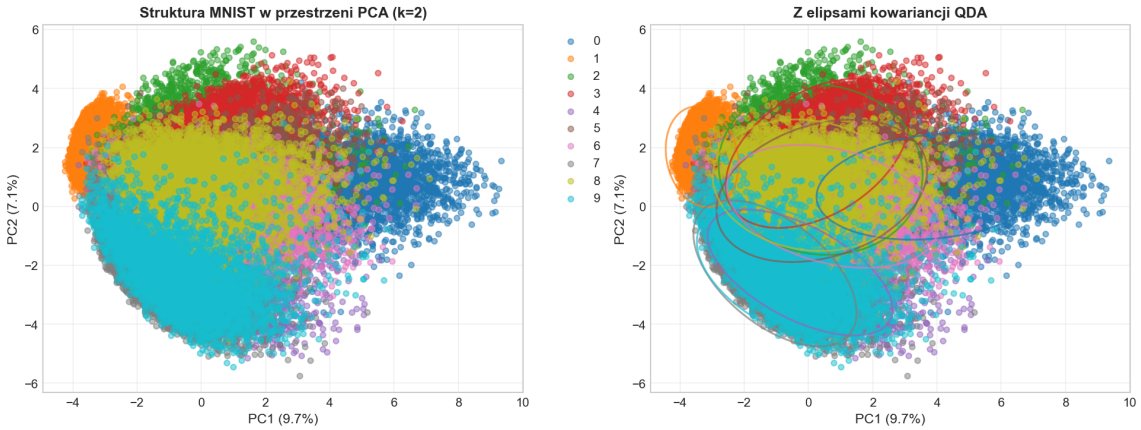

Rysunek 4: MNIST w PCA ($k = 2$) oraz PCA ($k = 2$) z elipsami kowariancji QDA.

Dyskusja

- Dla $k = 2$ suma wyjaśnionej wariancji PC1+PC2 wynosi ok. 16.9%, więc wizualizacja jest poglądowa.
- Na rzutach 2D widać nakładanie się klas, szczególnie w grupie cyfr 3/5/8 oraz również 4/9; jest to spójne z ideą, że małe D_B powinno oznaczać większą liczbę pomyłek.
- Zwiększanie k poprawia odwzorowanie wariancji, ale w QDA rośnie złożoność estymacji Σ_c (wiele parametrów), co może pogarszać stabilność numeryczną i uogólnianie.
- Ograniczenia: założenie Gaussa jest przybliżeniem dla danych obrazowych (MNIST).